


* Orthogonal projection

- $L \subseteq \mathbb{R}^n$ 을 따를 때, $L^\perp = \{x \in \mathbb{R}^n : x^T y = 0 \text{ for all } y \in L\}$
- L^\perp 는 \mathbb{R}^n 의 부분공간이며, $L \cap L^\perp = \{0\}$. (교집합이 없음)
- \mathbb{R}^n 에 있는 x 는 아래와 같이 표현 가능

$$\rightarrow x = x_L + x_{L^\perp}$$

$\rightarrow x_L \in L$ 이며, x 를 L 로 정사영시킨 벡터



$$\|x - x_L\|_2 \leq \|x - y\|_2 \quad \forall y \in L$$

* Idempotent matrix

- $A^2 = A$ 이라면 A 는 Idempotent matrix 라고 함.

① Ax 는 x 를 $C(A)$ 로 정사영시킨 것. ($\forall x \in \mathbb{R}^n$) \rightarrow Q. 근데 왜 $C(A)$ 일까?

② $N(A) \perp C(A)$ 이며 $x^T y = 0 \quad \forall x \in N(A), \forall y \in C(A) \rightarrow$ Q. $N(A)$ vs $C(A)$?

③ A 는 대칭 행렬 & 역행렬

- 위 조건 만족하면 A 는 $C(A)$ 로의 정사영 행렬이라 함.

① $A \rightarrow C(A)$ 로 볼.

$C(A) \cdot x \rightarrow x$ 를 A 로 span 한 것.



Q. $N(A)$ vs $C(A)$?

① $N(A)$ 는 A 의 영공간.

$Ax = 0$ 을 만족하는 벡터들

• $C(A)$ 는 A 의 행공간으로,

기저 역할을 함.

• x^T 라고 하면 사실상 $C(A)$ 들의 조합이므로

영공간 A 나 행공간 x 의 내적은

0

* Symmetric matrix

$$① A^T = A$$

② A 의 고유값은 0 또는 1

$$③ \text{rank}(A) + \text{rank}(I_n - A) = n$$

- 위 세가지 특징은 아래 설명될

$$① \text{rank}(A) = \text{tr}(A)$$

Q. $\text{rank}(A)$, $\text{tr}(A)$ 묶어 정리.

$$② I_n - A : N(A) \text{로 정사영}$$

* Orthogonal projection

① $A+B$ 가 정사영인 경우.

$$\cdot \mathcal{C}(A+B) = \mathcal{C}(A) + \mathcal{C}(B)$$

$$\cdot \mathcal{N}(A+B) = \mathcal{N}(A) \cap \mathcal{N}(B)$$

$$\cdot [A+B : \text{orthogonal projection} \iff \mathcal{C}(A) \perp \mathcal{C}(B)]$$

(\Rightarrow 증명) orthogonal 하므로.

$$(A+B)^2 = A+B, \text{ 이는 } AB+BA=0 \text{ 임을 의미}$$

$$AB+BA=0$$

$$A^2B + ABA = AB + ABA = \underline{AB(I+A)} = 0$$

$$AB=0 \text{ 이거나 } I+A=0$$

$$\left(\underline{x \in \mathcal{C}(A)} \text{ 이면 } Bx=0 \text{ 일 } \vee \text{ 여기는 왜 증명?} \right.$$

$$x \text{ 를 곱해서 } (I+A)ABx = 0 = AB(I+A)$$

$$\|Bx\|^2 = x^T B(I+A)^2 Bx = x^T B(I+3A)Bx = 0 \quad \therefore Bx=0$$

(\Leftarrow 증명)

$\mathcal{C}(A) \perp \mathcal{C}(B)$ 하므로

$$(A+B)^2 = A^2 + B^2 + \cancel{AB} + \cancel{BA} = A+B$$

$\therefore A+B$ 는 orthogonal projection.

$$A, B : \text{symetric} \rightarrow A+B : \text{symetric}$$

② AB 가 orthogonal projection

$$\cdot \mathcal{C}(AB) = \mathcal{C}(A) \cap \mathcal{C}(B)$$

$$\cdot \mathcal{N}(AB) = \mathcal{N}(A) + \mathcal{N}(B)$$

$$\cdot [AB : \text{orthogonal projection} \iff AB=BA \text{ 증명.}]$$

(\Rightarrow 증명) symetric

$$(AB)^T = AB = \overbrace{B^T A^T} = BA$$

(\Leftarrow 증명)

A 가 대칭 & idem

$$(AB)^2 = \underline{AB}AB = AAB B = AB$$

③ T.F.A.E

- $C(A) \subset C(B)$
- $AB = A$
- $BA = A$
- $B - A$ 는 orthogonal projection

* 추가 내용

- $X = (x_1, x_2, \dots, x_p)$ 의 $n \times p$ 행렬이고, $H = X(X^T X)^{-1} X^T$ 이면

H 는 $C(X)$ 의 orthogonal projection 일.

$$① H^2 = H$$

$$② C(H) \perp N(H)$$

$$③ C(H) = C(X)$$

- 만약 $n \times p$ 행렬인 Y 가 $C(Y) = C(X)$ 일 때, $X(X^T X)^{-1} X^T = Y(Y^T Y)^{-1} Y^T$

* 선형 회귀 - 벡터

- $x_i \in \mathbb{R}^p, y_i \in \mathbb{R}$ 일 때 $(x_1, y_1) \dots (x_n, y_n)$ 이라 가정.
- 선형 회귀의 목적은 $\beta_0 + \sum_j \beta_j x_{ij}$ 은 y_i 에 근사시키는 것.
- Least Square Estimator (LSE) 는
$$\underset{\beta_0, \beta_1, \dots, \beta_p}{\text{minimize}} \sum_i (y_i - \beta_0 - \sum_j \beta_j x_{ij})^2$$

* 선형 회귀 - 행렬

- $Y = (y_1, \dots, y_n)^T, y_i \in \mathbb{R}^n$ (n 차원 벡터)
- X 는 i 번째 열이 $(1, x_i^T)$ 인 $n \times (p+1)$ 행렬 $\begin{bmatrix} 1 & 1 & 1 & \dots & 1 \\ \vdots & x_1^T & x_2^T & \dots & x_n^T \end{bmatrix}$
- 행렬 식 일때는
$$\text{LSE } \hat{\beta} = \underset{\beta \in \mathbb{R}^{p+1}}{\text{minimize}} \|Y - X\beta\|_2^2 = (Y - X\beta)^T (Y - X\beta) = R(\beta)$$
- 만약 $\text{rank}(X) = p+1$, LSE 는
$$\hat{\beta} = (X^T X)^{-1} X^T Y.$$
- $\hat{y} = X\hat{\beta} = X(X^T X)^{-1} X^T Y = HY$ (\hat{y} 는 Y 가 $C(X)$ 의 orthogonal projection).


- 만약 입력 변수가 $1^T x_j = \sum_i x_{ij} = 0 \quad \forall j, 1 = (1, \dots, 1)^T$ & $x_j = (x_{1j}, \dots, x_{nj})^T$
- 이 경우에는 $\hat{\beta}_0 = \sum_i \frac{y_i}{n} \rightarrow (y - \hat{\beta}_0 \mathbf{1}) \perp y$
- 만약, x_1, x_2, \dots, x_p 가 orthogonal 하면, $\hat{\beta}_j = \frac{x_j^T y}{\|x_j\|_2^2} \rightarrow \frac{x x^T}{\|x\|_2^2} : X$ 의 정사영

* 다중 회귀 by orthogonalization

- 선형 회귀에서, 만약 $p=1$ 이면, $\hat{\beta}_1 = \frac{(x_1 - \bar{x}_1 \mathbf{1})}{\|x_1 - \bar{x}_1 \mathbf{1}\|_2^2} y, \bar{x}_j = \sum_i \frac{x_{ij}}{n}$
 $n \times 2$ 의 행렬
- 위 식은 아래처럼 적용 가능.
 - ① 잔차인 $z = x_1 - \bar{x}_1 \mathbf{1}$ 을 만들기 위해 x_1 을 $\mathbf{1}$ 로 회귀
 - ② $\hat{\beta}_1$ 계수를 얻기 위해 y 를 잔차 z 로 회귀
- 이러한 접근은 $p > 1$ 일때 일반화됨.

→ Ax 가 x 를 A 로 내적 (정사영) 하는 건 알겠음.

→ 잔차 $x_1 - \bar{x}_1 \mathbf{1} = x_1 - \sum \frac{x_{1i}}{n}$ 은 뭐지?

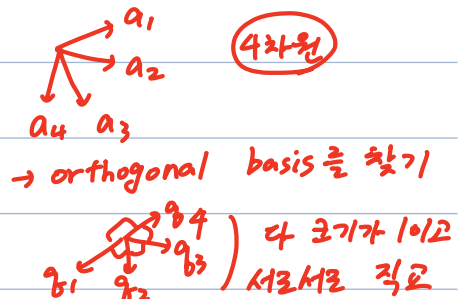


* Gram-Schmidt orthogonalization

- 연속적인 직교화에 의한 회귀
- $z_0 = x_0 = \mathbf{1}$
- for $j = 1, \dots, p$ 과정에 x_j 를 z_0 벡터 z_{j-1} 에 회귀
- $\hat{\gamma}_{lj} = \frac{z_l^T x_j}{\|z_l\|_2^2}$


* 그람-슈미트 직교화

a_1, a_2, a_3, a_4



* QR decomposition

- $\Gamma = (\hat{\gamma}_{kj})$ 이고, $Z = (z_0, z_1, \dots, z_p), D = \text{diag}(\|z_j\|_2)$
- 이면, $X = Z\Gamma = Z \cdot D^{-1} D \cdot \Gamma \stackrel{\text{ref}}{=} QR$.
- $Q^T Q = I_{p+1}$ Q. 왜 $p+1$?



$$v_1 = a_1,$$

$$v_2 = a_2 - \left(a_2^T \cdot \frac{v_1}{\|v_1\|_2} \right) \cdot \frac{v_1}{\|v_1\|_2}$$

정사영 크기 방향 벡터

$$= a_2 - \frac{a_2^T \cdot v_1}{\|v_1\|_2^2} v_1$$

Sampling distribution of $\hat{\beta}$ and $\hat{\sigma}^2$

- X 가 non-random한 선형 회귀에서는 아래 식을 가정함.

$$\varepsilon_i = y_i - x_i^T \beta \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$$

↳ 이 말은 즉슨, $y_i = x_i^T \beta + \varepsilon_i$ 이므로 $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ 일.

- $\text{rank}(X) = p+1$ 이고, $n > p+1$ 이라 가정함.

- 모수 추정 결과, 다음과 같이 나옴

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

$$\hat{\sigma}^2 = \frac{\|y - \hat{y}\|_2^2}{n - p - 1}$$

- $z \sim \mathcal{N}(0_n, I_n)$ 이고 $A \in \mathbb{R}^{n \times n}$ 이 직교 행렬 일때 아래 식을 만족함.

$$z^T A z \sim \chi_k^2.$$

- (증명)

$$z \sim \mathcal{N}(0_n, I_n)$$

$$A = V V^T \text{ (spectral decomp.)} = v_1 v_1^T + v_2 v_2^T + \dots + v_k v_k^T.$$

$$z^T A z = (v_1^T z)^2 + (v_2^T z)^2 + \dots + (v_k^T z)^2 \sim \chi_k^2$$

$$A = V D V^T$$

$$z^T A z$$

$$= z^T V D V^T z$$

$$V^T z \sim \mathcal{N}(0, V^T \text{Var}(z) V) \quad \text{Cov}(V_j^T z, V_i^T z) = V_j^T \text{Cov}(z, z) V_i^T = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases}$$

$$= \mathcal{N}(0_n, I_n)$$

$$\therefore z^T A z = \tilde{z}^T D \tilde{z} \quad (\tilde{z} = V^T z) \sim \chi_k^2$$

$$y_i = x_i^T \beta + \varepsilon_i, \quad y = X \beta + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$$

$$\hat{\beta} = (X^T X)^{-1} X^T y = (X^T X)^{-1} X^T (X \beta + \varepsilon)$$

$$= \beta + (X^T X)^{-1} X^T \cdot \varepsilon \quad \rightarrow \text{여기서 } \varepsilon \sim \mathcal{N}(0, (X^T X)^{-1} X^T \cdot \sigma^2 \cdot X \cdot (X^T X)^{-1})$$

$$= \mathcal{N}(0, \sigma^2 \cdot (X^T X)^{-1})$$

$$\hat{\sigma}^2 =$$